

LLM ENGINEER · FINAL PROJECT

AthleteCore

AI sports memory & coaching

Memory-driven assistant for professional badminton athletes – voice logs, grounded analysis, methodology RAG.

Не просто чат-бот, а система памяти, анализа и grounded coaching для спортсмена.

DEMO PERSONA: AIGERIM · COURSE MVP

Спортсмен теряет контекст — LLM может его выдумать

- Тренировки, матчи, усталость и ошибки остаются в голове и заметках — не в системе
- Обычный chatbot не помнит историю между сессиями
- LLM может «разобрать» прошлую тренировку, которой не было
- Нужен честный персональный коучинг на реальных данных, не generic советы

CHATBOT


«Отдыхай и работай над техникой» — без истории

ATHLETECORE

Повторяющиеся паттерны → конкретный план (если есть LTM)

AthleteCore — инженерный продукт, не demo-чат

Один запрос: от голоса до coaching-ответа




«Сегодня была тренировка. Плохо принимала смэши, устала к концу, но подача стала стабильнее.»

- Router: `NEW_EVENT_LOG` → Analyst анализирует → memory write в фоне
- Через неделю система помнит паттерны усталости и смэшей — не начинает с нуля

Memory ≠ RAG — разные слои данных

- 1 Raw input**
Text или voice (MediaRecorder → webm)
- 2 Transcription**
OpenAI Whisper whisper-1 · POST /api/transcribe
- 3 Structured extraction**
event_date, session_type, facts JSON, fatigue, problems
- 4 SQLite Memory (LTM)**
Персональная история этого спортсмена
- 5 Qdrant RAG**
Спортивная методология из coaching PDF (не личные логи)
- 6 Langfuse trace**
Routing, LLM calls, latency_trace в dev mode

System mindmap



Conditional multi-agent workflow



`route_after_planner · route_after_memory` — conditional edges in `build.py`

- Память загружается только когда router решает `needs_memory=true`
- Analyst — Sonnet; router/direct — gpt-4o-mini (cost vs quality)
- SQLite checkpointer — continuity по `thread_id`

LTM в SQLite — не просто chat history

- **event_date** — нормализация в коде, не freeform LLM
- **raw_user_text + facts JSON** — structured sport events
- **write-gate** — не пишем шум и assistant-only текст
- **background extraction** — после ответа, не блокирует UX
- **past-event guard** — lookup до Analyst LLM

Missing data — система не выдумывает тренировки

«Разбери тренировку 10 февраля»



Check memory / SQL




Found?

The system does not hallucinate missing training logs.

pytest: test_api_chat_past_event · past_event_guard.py

Methodology from coaching books — not from imagination



- Collection: `sports_methodology` · text-embedding-3-small
- Drills, footwork, recovery, tactics — cite `source` filename
- Lexical fallback if Qdrant unavailable · optional cross-encoder rerank
- **Note:** output/*.md is local after ingest — not bundled in git

Action layer для agents и Cursor

Server: `mcp_server/server.py` · shared code: `backend/app/mcp_tools/`

Chat UI uses same tools in-process — MCP server is for Cursor / external agents

CUSTOM SKILL

Domain expertise for Cursor agents

Evals & tracing — честно про scope

✓ Implemented

- 25 safety golden cases (20 generic + 5 AthleteCore)
- ~195 pytest — routing, memory, RAG, anti-hallucination
- **Langfuse** tracing (LangSmith — not in code)
- **latency_trace** + **analyst_trace** in dev mode
- Run-over-run: `--compare-previous` safety regression

✗ Not claimed

- No production A/B with real users
- No formal Analyst prompt v1 vs v2 runner
- No LLM-as-judge production pipeline
- Analyst 40-case golden — planned, not automated

Wording: offline safety eval + regression tests + latency benchmark

MVP today — что работает и что partial

Implemented

- Chat LangGraph
- LTM + write-gate
- RAG Qdrant
- Whisper voice
- MCP 4 tools
- Custom Skill
- Langfuse
- Safety evals

Partial / Missing

- History UI — mock seed data
- HITL schedule UI
- Video MVP
- Auth / multi-user
- Formal Analyst A/B
- LangSmith
- BWF scraping

Trade-off: Sonnet Analyst (quality) vs mini router (latency/cost) · SQLite LTM (simple deploy) vs scale-out vector DB

ROADMAP · CLOSING

Что дальше

- Real History API UI (replace mock pages)
- Coach dashboard · federation B2B2C direction
- Bigger eval dataset · formal offline A/B
- Multi-sport expansion · production hardening

AthleteCore is not a chatbot.

It is a memory-driven, grounded AI coaching system for athletes.

Спасибо · Вопросы?